EM算法类似于kmeans算法, 但是EM算法其实包括了Kmeans算法

首先初始步骤分为两个,先随机选取k个点作为簇类中心,之后为每一个簇类设定参数,包括均值,和协方差矩阵,每一个簇类的先验概率。均值代表簇的中心,协方差矩阵代表簇类的形状,先验概率代表所有点分到这个簇类的概率

哈哈一开始每一个中心点的先验概率都是1/k,协方差矩阵为单位矩阵,均值就是中心点

EM算法分为两个主要步骤首先是期望步骤,用算法评估每个数据点x属于每个聚类C的概率P(C|x)。这个步骤不像是kmeans中直接通过最短距离把x分类到最近的簇中,而是先计算出x分类到所有簇的概率

之后是最大化步骤Maximum,用前一个步骤也就是期望步骤算出来的概率来更新每个簇类的参数最后使得来自刚刚E步骤的下的似然对数函数最大

Expectation Step

$$p(C_j | x_i) = \frac{p(x_i | C_j) \cdot p(C_j)}{p(x_i)} = \frac{p(x_i | C_j) \cdot p(C_j)}{\sum_{i} p(x_i | C_j) \cdot p(C_j)}$$

Maximization Step

$$\mu_{j} = \frac{\sum_{i} p(C_{j} \mid x_{i}) \cdot x_{i}}{\sum_{i} p(C_{j} \mid x_{i})} \qquad \Sigma_{j} = \frac{\sum_{i} p(C_{j} \mid x_{i}) \cdot (x_{i} - \mu_{j}) \cdot (x_{i} - \mu_{j})^{T}}{\sum_{i} p(C_{j} \mid x_{i})} \qquad p(C_{j}) = \frac{\sum_{i} p(C_{j} \mid x_{i})}{N}$$

好,那第一个算exp的,首先p(C)初始化为1/k,就带进去算,算出来tm一堆 $p(C_j|x_i)$,好,现在有了每一个点属于每一个簇的期望值(可能性)

之后重新校准每一个簇的属性包括均值和协方差

重新计算他们的平均值和协方差, 用极大似然算出每一个簇的均值和方差参数

同时更新这几个簇的先验概率